

## ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ

### Кейс 5: Метрические методы классификации

**Выполнили:**

Дубовик Никита Спартакович (Группа J3210)  
Таряник Антон Александрович (Группа J3211)  
Бессонов Александр Русланович (Группа J3213)

# Содержание

|                                   |    |
|-----------------------------------|----|
| Постановка задачи                 | 2  |
| Цели работы                       | 3  |
| Обоснование использования методов | 3  |
| Описание используемых датасетов   | 4  |
| Реализация алгоритмов             | 4  |
| Экспериментальные результаты      | 6  |
| Выводы                            | 10 |
| Заключение                        | 10 |
| Ссылки на ресурсы                 | 11 |

## Постановка задачи

Пусть дана обучающая выборка  $X^\ell = \{(x_i, y_i)\}_{i=1}^\ell$ , где  $x_i \in \mathbb{R}^n$  — вектор признаков,  $y_i \in Y$  — метка класса. Для измерения близости объектов используется взвешенная метрика Минковского:

$$\rho(x, x_i) = \left( \sum_{j=1}^n w_j |x_j - x_{i,j}|^p \right)^{1/p},$$

где  $w_j > 0$  — веса признаков,  $p \geq 1$  — параметр метрики.

Объекты обучающей выборки упорядочиваются по возрастанию расстояния до объекта  $x$ :

$$\rho(x, x_{(1)}) \leq \rho(x, x_{(2)}) \leq \dots \leq \rho(x, x_{(\ell)}).$$

Рассматривается обобщённый метрический классификатор:

$$a(x; X^\ell) = \arg \max_{y \in Y} \Gamma_y(x), \quad \text{где} \quad \Gamma_y(x) = \sum_{i=1}^{\ell} [y_{(i)} = y] \cdot w(i, x).$$

Требуется исследовать частные случаи данного правила:

- метод ближайшего соседа (1NN):  $w(i, x) = [i \leq 1]$ ;
- метод  $k$  ближайших соседей (kNN):  $w(i, x) = [i \leq k]$ ;
- метод  $k$  взвешенных ближайших соседей:  $w(i, x) = [i \leq k] \cdot v_i$ , где  $v_i$  — убывающие веса соседей;
- окно Парзена фиксированной ширины:  $a(x; X^\ell, h, K) = \arg \max_{y \in Y} \sum_{i=1}^{\ell} [y_{(i)} = y] K \left( \frac{\rho(x, x_{(i)})}{h} \right)$ ;
- окно Парзена переменной ширины:  $a(x; X^\ell, k, K) = \arg \max_{y \in Y} \sum_{i=1}^{\ell} [y_{(i)} = y] K \left( \frac{\rho(x, x_{(i)})}{\rho(x, x_{(k+1)})} \right)$ .

Дополнительно требуется:

1. Подобрать параметры  $k$ ,  $p$ ,  $h$  и вид ядра  $K$  по критерию скользящего контроля (LOO);
2. Проверить влияние предварительного масштабирования признаков на качество классификации;
3. Построить карты классификации и границы решений для синтетического датасета;
4. Построить графики зависимости ошибки от параметров алгоритмов;
5. Исследовать устойчивость weighted-kNN к выбросам;
6. Реализовать вычисление профиля компактности  $\Pi(m)$  и проверить его корреляцию с качеством 1NN;
7. Реализовать жадный алгоритм отбора эталонов и сравнить эффективность полного и сокращённого 1NN.

## Цели работы

1. Реализовать с нуля и сравнить следующие метрические классификаторы: 1NN, kNN, взвешенный kNN, окно Парзена фиксированной и переменной ширины.
2. Исследовать влияние параметров метрики  $p$ , числа соседей  $k$ , ширины окна  $h$  и вида ядра  $K$  на качество классификации, оцениваемое по средствам LOO.
3. Оценить влияние предобработки данных, в частности масштабирования признаков, на итоговое качество классификации.
4. Визуализация и анализ карт классификации и границ решений на двумерных синтетических данных при различных настройках алгоритмов.
5. Расчёт и анализ профиля компактности  $\Pi(m)$ , проверка его корреляции с качеством метода 1NN.
6. Проанализировать возможность ускорения алгоритма за счет отбора эталонов без существенной потери качества используя жадный алгоритм.
7. Сформулировать выводы о влиянии выбора метрики, параметров сглаживания и стратегии отбора эталонов на качество, устойчивость и вычислительную эффективность алгоритмов.

## Обоснование использования методов

Метрические алгоритмы классификации выбраны в качестве объекта исследования по следующим причинам:

- **Непараметрическая природа.** Метрические методы не предполагают наличия априорного знания о распределении данных или виде разделяющей поверхности. Они опираются исключительно на локальную структуру выборки, что делает их универсальным инструментом для анализа данных с неизвестной или сложной геометрией.
- **Адаптивность.** Использование взвешенной метрики Минковского позволяет гибко настраивать окрестность объектов и учитывать разную информативность признаков.
- **Интерпретируемость.** Принятие решения основывается на непосредственном сравнении с конкретными объектами обучающей выборки, что упрощает объяснение результатов модели и анализ ошибок.
- **Эффективность LOO-оценки.** Метрические алгоритмы удобно настраивать с помощью процедуры скользящего контроля (LOO). Такой подход даёт честную оценку ошибки, даже если данных немного. Это позволяет надёжно подобрать параметры модели без риска переобучения и без необходимости выделять отдельную тестовую выборку, которая при малом объёме данных приводит к потере ценной информации.

Однако метрические методы имеют ограничения: они чувствительны к проклятию размерности — при большом числе признаков и малом объёме выборки расстояния теряют способность различать объекты.

## Описание используемых датасетов

В ходе выполнения работы использовались следующие наборы данных:

- **Iris** (`sklearn.datasets.load_iris`) — классический датасет для задач многоклассовой классификации. Содержит 150 объектов, распределённых по 3 классам, и 4 числовых признака (длина и ширина чашелистика и лепестка). Использовался для подбора гиперпараметров по критерию LOO, анализа профиля компактности и отбора эталонов.
- **Wine** (`sklearn.datasets.load_wine`) — датасет для многоклассовой классификации, содержащий 178 объектов (3 класса) и 13 числовых признаков, представляющих собой химический состав вин. Применялся для демонстрации влияния предварительного масштабирования признаков на качество работы метрических алгоритмов.
- **Breast Cancer Wisconsin** (`sklearn.datasets.load_breast_cancer`) — датасет бинарной классификации, включающий 569 объектов и 30 числовых признаков, полученных при тонкоигольной аспирации. Использовался для исследования устойчивости алгоритмов (kNN и взвешенного kNN) к наличию выбросов и зашумлённости меток.
- **make\_moons** (`sklearn.datasets.make_moons`) — синтетический двумерный датасет, состоящий из 200 объектов, образующих два переплетённых полумесяца (2 класса), с добавлением гауссовского шума. Предназначен для визуализации карт классификации и нелинейных границ принятия решений.

Все датасеты представлены в виде матрицы признаков  $X \in \mathbb{R}^{\ell \times n}$  и вектора целевых меток  $y \in \{0, \dots, C-1\}^\ell$ .

## Реализация алгоритмов

Все алгоритмы реализованы с нуля на языке Python без использования готовых реализаций метрических классификаторов из библиотеки scikit-learn.

### Базовый класс и метрика

В основе всех реализованных методов лежит вычисление попарных расстояний с использованием взвешенной метрики Минковского:

$$\rho(x, x_i) = \left( \sum_{j=1}^n w_j |x_j - x_{i,j}|^p \right)^{1/p}.$$

Обобщённый метрический классификатор принимает решение на основе оценки функций принадлежности классам:

$$a(x; X^\ell) = \arg \max_{y \in Y} \Gamma_y(x), \quad \text{где} \quad \Gamma_y(x) = \sum_{i=1}^{\ell} [y_{(i)} = y] \cdot w(i, x).$$

## Методы $k$ ближайших соседей

Реализованы три варианта метода ближайших соседей, отличающиеся правилом задания весов  $w(i, x)$ :

- **1NN (метод ближайшего соседа):** вес имеет только один ближайший объект:

$$w(i, x) = [i \leq 1].$$

- **kNN (метод  $k$  ближайших соседей):** вес распределяется равномерно на  $k$  ближайших объектов:

$$w(i, x) = [i \leq k].$$

- **Weighted-kNN (взвешенный kNN):** вес убывает в зависимости от ранга соседа. В реализации использовались линейно убывающие веса  $v_i = k - i + 1$ :

$$w(i, x) = [i \leq k] \cdot v_i.$$

## Окно Парзена

Методы на основе ядерного сглаживания используют функцию ядра  $K(u)$  для определения вклада объектов. В работе реализованы следующие ядра: равномерное (uniform), треугольное (triangular), Епанечникова (epanchnikov), квартическое (quartic) и гауссовское (gaussian).

- **Окно Парзена фиксированной ширины:** радиус окна  $h$  задаётся глобально для всего пространства признаков:

$$a(x; X^\ell, h, K) = \arg \max_{y \in Y} \sum_{i=1}^{\ell} [y_i = y] K \left( \frac{\rho(x, x_i)}{h} \right).$$

- **Окно Парзена переменной ширины:** радиус окна адаптивно подстраивается под локальную плотность данных и равен расстоянию до  $(k + 1)$ -го соседа:

$$a(x; X^\ell, k, K) = \arg \max_{y \in Y} \sum_{i=1}^{\ell} [y_i = y] K \left( \frac{\rho(x, x_i)}{\rho(x, x_{(k+1)})} \right).$$

## Профиль компактности и отбор эталонов

**Профиль компактности**  $\Pi(m)$  показывает долю объектов, для которых  $m$ -й сосед принадлежит другому классу. Он вычисляется по формуле:

$$\Pi(m) = \frac{1}{\ell} \sum_{i=1}^{\ell} [y_i \neq y_i^{(m)}].$$

Для ускорения классификации реализованы жадные алгоритмы **отбора эталонов**:

- *Последовательное добавление:* начальное множество эталонов содержит по одному объекту каждого класса. Далее итеративно добавляется объект, на котором текущая модель допускает ошибку.
- *Последовательное удаление:* начальное множество эталонов совпадает с полной обучающей выборкой. Далее итеративно удаляется объект, исключение которого не ухудшает (или минимально ухудшает) качество на обучающей выборке, пока это возможно.

# Экспериментальные результаты

## Влияние масштабирования

Метрические методы критически зависят от масштаба признаков. Для демонстрации этого эффекта был использован датасет **Wine** и метод 1NN. Результаты до и после применения стандартизации (**StandardScaler**) представлены в таблице 1.

Таблица 1: Влияние масштабирования на качество 1NN (датасет Wine)

| Состояние данных                    | Accuracy (1NN) |
|-------------------------------------|----------------|
| Без масштабирования                 | 0.7963         |
| С масштабированием (StandardScaler) | 0.9630         |

Масштабирование признаков позволило повысить долю верных ответов с 79.6% до 96.3%, что подтверждает необходимость приведения признаков к единому масштабу перед применением метрики Минковского. В дальнейших экспериментах использовались только масштабированные данные.

## Визуализация границ решений

Для анализа геометрии разделяющих поверхностей был использован синтетический датасет **make\_moons**. На рисунках 1 и 2 представлены карты классификации.




Рис. 1: Границы решений: kNN ( $k = 5$ ) и окно Парзена фиксированной ширины ( $h = 0.5$ , ядро Епанечникова)




Рис. 2: Границы решений: окно Парзена фиксированной ( $h = 0.5$ ) и переменной ( $k = 10$ ) ширины с гауссовским ядром

Метод  $kNN$  формирует кусочно-линейные и фрагментированные границы, в то время как окно Парзена обеспечивает более гладкие разделяющие поверхности. Окно переменной ширины лучше адаптируется к локальной плотности, сужая окно в густых областях и расширяя в разреженных.

## Подбор параметров по критерию LOO

Подбор оптимальных гиперпараметров осуществлялся на датасете **Iris** с помощью процедуры скользящего контроля (Leave-One-Out).




Рис. 3: Зависимость LOO-ошибки метода  $kNN$  от числа соседей  $k$  и параметра метрики  $p$

Для метода  $kNN$  наименьшая ошибка (0.0267) достигается при  $k = 16$  и  $p = 2.0$  (евклидова метрика). Как видно из рисунка 3, выбор параметра  $p$  слабо влияет на ошибку при  $p \geq 2$ , однако малые значения  $k$  приводят к переобучению.





Рис. 4: Зависимость LOO-ошибки окна Парзена фиксированной ширины от  $h$  и вида ядра

Для **окна Парзена фиксированной ширины** оптимальными оказались ширина окна  $h = 0.64$  и гауссовское ядро (ошибка 0.0400). При малых  $h$  ошибка стремится к максимуму из-за переобучения, а при больших — из-за излишнего сглаживания (рисунок 4).




Рис. 5: Зависимость LOO-ошибки окна Парзена переменной ширины от  $k$  и вида ядра

Для **окна Парзена переменной ширины** лучшая комбинация:  $k = 15$  и равномерное ядро (uniform) с ошибкой 0.0267. Равномерное ядро в сочетании с адаптивным радиусом показало высокую стабильность (рисунок 5).

## Устойчивость к выбросам

Для оценки робастности алгоритмов к зашумлённым данным использовался датасет **Breast Cancer Wisconsin**, в котором у 10% объектов были инвертированы целевые метки. Сравнение проводилось для  $k = 10$ .

Таблица 2: Устойчивость алгоритмов к выбросам (зашумлённый Breast Cancer)

| Модель ( $k = 10$ )       | LOO Ошибка |
|---------------------------|------------|
| Обычный kNN               | 0.1265     |
| Взвешенный kNN (Weighted) | 0.1195     |

Взвешенный kNN продемонстрировал меньшую ошибку (0.1195 против 0.1265), что подтверждает его большую устойчивость к выбросам за счёт снижения веса объектов, находящихся дальше от классифицируемого.

## Профиль компактности

Профиль компактности  $\Pi(m)$  для датасета **Iris** представлен на рисунке 6.




Рис. 6: Профиль компактности датасета Iris

Низкие значения  $\Pi(m)$  при малых  $m$  (в частности,  $\Pi(1) \approx 0.053$ ) свидетельствуют о высокой компактности классов и хорошем разделении, что напрямую коррелирует с низкой ошибкой метода 1NN на данном датасете.

## Эффективность отбора эталонов

Результаты работы жадных алгоритмов отбора эталонов на датасете **Iris** представлены в таблице 3. В качестве базовой модели использовался 1NN.

Таблица 3: Эффективность алгоритмов отбора эталонов (Iris)

| Набор данных        | Размер | Ошибка (LOO/Train) | Время предсказания (сек) | Время отбора (сек) |
|---------------------|--------|--------------------|--------------------------|--------------------|
| Полный датасет      | 150    | 0.0533             | 0.005746                 | 0.0000             |
| Эталон (Добавление) | 24     | 0.0000             | 0.002405                 | 0.0642             |
| Эталон (Удаление)   | 18     | 0.0000             | 0.002248                 | 51.2319            |

Оба метода позволили существенно сократить размер эталонного множества (до 24 и 18 объектов соответственно) при сохранении идеального качества на обучающей выборке. Время предсказания сократилось более чем в два раза. Алгоритм последовательного

удаления обеспечил более компактное множество эталонов, однако потребовал значительно больших вычислительных затрат на этапе обучения (51.2 сек против 0.06 сек) из-за необходимости многократного пересчёта модели.

## Выводы

На основе проведённых экспериментов сформулированы следующие выводы:

1. **Выбор метрики.** Параметр  $p$  метрики Минковского оказывает слабое влияние на качество, при  $p$  из  $[1, 3]$ . При наличии признаков с разными масштабами критически важно применять масштабирование или использовать веса признаков  $w_j$ .
2. **Число соседей  $k$ .** Малые  $k$  приводят к переобучению. Увеличение  $k$  сглаживает границу решения и повышает устойчивость к шуму, но может привести к недообучению на сложных данных. Оптимальное  $k$  следует подбирать с использованием LOO под конкретные данные.
3. **Ширина окна  $h$ .** Для метода Парзена малые значения  $h$  приводят к переобучению, большие — к излишнему сглаживанию. Оптимальная ширина зависит от характера данных и уровня шума. Для большинства ядер и датасета Iris оптимальной была ширина окна равная единице.
4. **Вид ядра  $K$ .** Выбор конкретной ядерной функции оказывает умеренное влияние на качество классификации при условии корректного подбора параметров сглаживания. Для окон переменной ширины, где радиус адаптивно подстраивается под локальную плотность данных, различия между ядрами при большом количестве соседей ярко выражено: равномерное и гауссово ядра показывают себя хуже в таком сценарии. В целом, выбор ядра менее критичен, чем предварительное масштабирование признаков и настройка ширины окна.
5. **Взвешивание соседей.** Взвешенный kNN демонстрирует лучшую устойчивость к выбросам по сравнению с обычным kNN, так как уменьшает вклад некоторых объектов в голосование.
6. **Отбор эталонов.** Жадный алгоритм добавления эталонов позволяет существенно сократить размер обучающей выборки без потери качества, что особенно важно для ускорения работы метрических методов на больших данных.
7. **Профиль компактности.** Низкие значения  $\Pi(m)$  при малых  $m$  коррелируют с хорошим качеством 1NN, что позволяет использовать профиль для предварительной оценки применимости метрических методов к задаче.

## Заключение

В ходе работы были реализованы и исследованы основные варианты метрических классификаторов. Показано, что качество методов существенно зависит от предобработки данных, выбора параметров метрики и стратегии взвешивания соседей. Предложенный алгоритм отбора эталонов позволяет ускорить классификацию без потери точности. Полученные результаты подтверждают эффективность метрических методов для задач с неизвестной структурой данных и малым объёмом выборки.

## Ссылки на ресурсы

- Репозиторий с кодом: [github.com/Toxele/Functional-Analysis-Cases-5-6-7](https://github.com/Toxele/Functional-Analysis-Cases-5-6-7)
- Использование ИИ-ассистента: [chat.qwen.ai/s/88fcc065-139e-438d-8352-33af54b2e877](https://chat.qwen.ai/s/88fcc065-139e-438d-8352-33af54b2e877)