

ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ

Кейс 6: Метрические методы регрессии

Выполнили:

Дубовик Никита Спартакович (Группа J3210)
Таряник Антон Александрович (Группа J3211)
Бессонов Александр Русланович (Группа J3213)

Содержание

1	Постановка задачи	2
2	Цели работы	2
3	Обоснование использования методов	2
4	Описание используемых датасетов	2
5	Реализация алгоритмов	3
5.1	Оценка Надарая–Ватсона	3
5.2	Робастная регрессия LOWESS	3
5.3	Подбор гиперпараметров	4
6	Экспериментальные результаты	4
6.1	Подбор гиперпараметров	4
6.2	Сравнение фиксированного и переменного окна	5
6.3	Исследование робастности NW и LOWESS	5
6.4	Применение на реальных данных и проклятие размерности	7
7	Выводы	7
8	Заключение	8
	Ссылки на ресурсы	8

1 Постановка задачи

Требуется реализовать метрические методы непараметрической регрессии (ядерное сглаживание Надарая-Ватсона с фиксированным и переменным окном, а также робастный LOWESS). Необходимо провести подбор оптимальных гиперпараметров, сравнить различные ядерные функции, исследовать устойчивость алгоритмов к выбросам на синтетических данных и оценить качество работы моделей на реальных датасетах.

2 Цели работы

1. Реализовать алгоритмы ядерной регрессии Надарая-Ватсона и LOWESS с нуля, без использования готовых библиотек машинного обучения.
2. Провести подбор гиперпараметров (ширина окна h , число соседей k , тип ядра) с помощью метода LOO.
3. Визуально и количественно оценить влияние гиперпараметров на модели.
4. Исследовать поведение моделей на данных с искусственными выбросами и доказать эффективность робастного перевзвешивания.
5. Оценить качество регрессии на реальных многомерных датасетах и проанализировать ограничения непараметрических методов.

3 Обоснование использования методов

Непараметрические методы регрессии, такие как оценка Надарая-Ватсона, не требуют задания глобальной формы зависимости. Они опираются на гипотезу непрерывности: близким объектам в пространстве признаков соответствуют близкие значения целевой переменной. Это позволяет моделировать сложные нелинейные функции без риска ошибиться с выбором семейства функций.

Метод LOWESS (Locally Weighted Scatterplot Smoothing) применяется для повышения робастности модели. Поскольку стандартная оценка NW является линейной комбинацией ответов, даже единичная аномалия может существенно исказить локальную оценку. LOWESS решает эту проблему за счёт итеративного перевзвешивания объектов на основе их ошибок, снижая влияние аномальных точек вплоть до их полного исключения.

4 Описание используемых датасетов

Для экспериментов использовались следующие наборы данных:

- **Синтетический одномерный датасет.** Сгенерирован по формуле $y = \sin(x) + \varepsilon$, где $\varepsilon \sim \mathcal{N}(0, 0.2^2)$, $x \in [0, 2\pi]$, объём выборки $n = 150$. Для исследования робастности к 10% точек добавлены выбросы со сдвигом $\Delta y \sim \mathcal{N}(0, 2.5^2)$.
- **Diabetes.** Стандартный датасет из библиотеки `scikit-learn` для задачи регрессии. Содержит 442 наблюдения и 10 числовых признаков, характеризующих пациентов.

Целевая переменная — количественная мера прогрессии заболевания через год после базового обследования. Признаки стандартизированы перед обучением.

- **California Housing.** Датасет с 20 640 наблюдениями и 8 признаками, описывающими районы Калифорнии (средний доход, возраст жилья, количество комнат и др.). Целевая переменная — медианная стоимость дома в единицах \$100 000. Признаки приведены к единому масштабу с помощью `StandardScaler`.

5 Реализация алгоритмов

5.1 Оценка Надарая–Ватсона

Оценка Надарая–Ватсона для точки x вычисляется по формуле:

$$\hat{f}(x) = \frac{\sum_{i=1}^{\ell} y_i K\left(\frac{\rho(x, x_i)}{h}\right)}{\sum_{i=1}^{\ell} K\left(\frac{\rho(x, x_i)}{h}\right)}, \quad (1)$$

где $\rho(\cdot, \cdot)$ — метрика расстояния (евклидова), $K(\cdot)$ — ядерная функция, $h > 0$ — ширина окна сглаживания.

Реализованы следующие ядра:

- равномерное: $K(u) = \frac{1}{2}\mathbb{I}\{|u| \leq 1\}$;
- треугольное: $K(u) = (1 - |u|)\mathbb{I}\{|u| \leq 1\}$;
- Епанечникова: $K(u) = \frac{3}{4}(1 - u^2)\mathbb{I}\{|u| \leq 1\}$;
- кватрическое: $K(u) = \frac{15}{16}(1 - u^2)^2\mathbb{I}\{|u| \leq 1\}$;
- гауссовское: $K(u) = \frac{1}{\sqrt{2\pi}}e^{-u^2/2}$.

Поддерживаются два режима выбора ширины окна:

- **Фиксированное окно:** параметр h задаётся явно;
- **Переменное окно:** $h(x) = \rho(x, x_{(k+1)})$, где $x_{(k+1)}$ — $(k+1)$ -й ближайший сосед точки x .

5.2 Робастная регрессия LOWESS

Алгоритм LOWESS выполняет итеративное перевзвешивание объектов для снижения влияния выбросов. На каждой итерации для объекта x_i вычисляется *leave-one-out* оценка:

$$a_i = \frac{\sum_{j=1, j \neq i}^{\ell} y_j \gamma_j K\left(\frac{\rho(x_i, x_j)}{h(x_i)}\right)}{\sum_{j=1, j \neq i}^{\ell} \gamma_j K\left(\frac{\rho(x_i, x_j)}{h(x_i)}\right)}, \quad (2)$$

где γ_j — текущие объектные веса. Затем вычисляются невязки $\varepsilon_i = |a_i - y_i|$ и обновляются веса по правилу:

$$\gamma_i^{\text{new}} = \tilde{K} \left(\frac{\varepsilon_i}{6 \cdot \text{med}\{\varepsilon_j\}} \right), \quad (3)$$

где $\tilde{K}$ — квартическое ядро, $\text{med}\{\cdot\}$ — медиана выборки. Процесс повторяется n_{iter} раз, после чего финальная оценка строится с учётом стабилизированных весов γ_i .

5.3 Подбор гиперпараметров

Оптимальные значения h , k и типа ядра выбирались минимизацией ошибки *leave-one-out* (LOO):

$$\text{MSE}_{\text{LOO}} = \frac{1}{\ell} \sum_{i=1}^{\ell} (\hat{f}_{-i}(x_i) - y_i)^2, \quad (4)$$

где $\hat{f}_{-i}$ — модель, обученная без i -го наблюдения. Для ускорения вычислений использовалась векторизованная реализация в `numpy`.

6 Экспериментальные результаты

6.1 Подбор гиперпараметров

На рис. 1 представлены зависимости ошибки LOO от ширины окна h (фиксированный режим) и числа соседей k (переменный режим) для различных ядер.




Рис. 1: Зависимость ошибки LOO от гиперпараметров для различных ядер

Наблюдается типичное поведение: при малых значениях h и k модель переобучается (высокая дисперсия), при больших — недообучается (высокое смещение). Оптимальные значения лежат в промежуточной области. Различия между ядрами незначительны: все они обеспечивают сопоставимое качество при правильно подобранной ширине окна. Наиболее чувствительным к увеличению h оказалось гауссово ядро, которое при больших окнах демонстрирует избыточное сглаживание.

Оптимальные гиперпараметры, найденные по минимуму MSE_{LOO} , представлены в табл. 1.

Таблица 1: Оптимальные гиперпараметры регрессии Надарая–Ватсона

Метод	Оптимальное ядро	Параметр	LOO MSE
NW (фиксированное окно)	uniform	$h = 0.41$	0.0392
NW (переменное окно)	uniform	$k = 12$	0.0393

6.2 Сравнение фиксированного и переменного окна

На рис. 2 показано сравнение прогнозов, полученных с фиксированным и переменным окном, на синтетических данных.




Рис. 2: Сравнение прогнозов с фиксированным и переменным окном

На однородных одномерных данных обе кривые практически совпадают и точно аппроксимируют истинную функцию $y = \sin(x)$. Прогноз с переменным окном демонстрирует чуть более выраженные локальные колебания, что объясняется адаптивным изменением ширины окна в зависимости от локальной плотности точек. В областях с равномерным распределением данных преимущества переменного окна не проявляются, однако в задачах с неравномерной плотностью оно позволяет лучше сохранять детализацию в разреженных областях.

6.3 Исследование робастности NW и LOWESS

Для оценки устойчивости к выбросам в синтетические данные были добавлены 10% аномальных наблюдений. Результаты сравнения стандартной оценки Надарая–Ватсона и робастного LOWESS представлены на рис. 3.




Рис. 3: Сравнение прогнозов обычного NW и LOWESS на данных с выбросами

Обычный алгоритм Надарая–Ватсона демонстрирует высокую чувствительность к выбросам: линия прогноза существенно отклоняется в сторону аномальных точек, искажая оценку истинной зависимости. Метод LOWess успешно идентифицирует выбросы и минимизирует их влияние, точно восстанавливая форму исходной функции.

Механизм робастного перевзвешивания иллюстрируется на рис. 4: после стабилизации веса γ_i для точек с выбросами обнуляются, в то время как для нормальных наблюдений веса остаются близкими к единице.




Рис. 4: Объектные веса γ_i после стабилизации LOWESS

Распределение остатков (рис. 5) подтверждает эффективность LOWess: ошибки обычного NW имеют тяжёлые хвосты из-за влияния выбросов, тогда как распределение ошибок LOWess ближе к симметричному с меньшей дисперсией.




Рис. 5: Распределение ошибок (остатков) на данных с выбросами

6.4 Применение на реальных данных и проклятие размерности

Качество моделей оценивалось на датасетах Diabetes и California Housing по метрикам MAE, RMSE и R^2 . Результаты представлены в табл. 2.

Таблица 2: Метрики качества на реальных датасетах (модель Надарая–Ватсона)

Метрика	Diabetes	California Housing
MAE	41.8141	0.4304
RMSE	54.0419	0.5721
R^2	0.4287	0.6153

Наблюдается снижение качества по сравнению с синтетическими одномерными данными, что объясняется *проклятием размерности*: в пространствах высокой размерности все точки становятся примерно равноудалёнными, что нарушает основную гипотезу метрических методов о локальной гладкости функции. Для улучшения результатов требуется:

- тщательная предобработка признаков (масштабирование, отбор);
- использование метрик, учитывающих структуру данных;
- применение методов уменьшения размерности (PCA, t-SNE) перед регрессией.

7 Выводы

В ходе выполнения работы были получены ответы на следующие исследовательские вопросы:

1. **Что влияет на качество сильнее — выбор ядра или выбор ширины окна?**

Выбор ширины окна (или числа соседей) оказывает доминирующее влияние на качество регрессии. Ширина окна напрямую управляет балансом между смещением и

дисперсией: слишком узкое окно приводит к переобучению, а слишком широкое — к излишнему сглаживанию. Выбор ядра влияет лишь на форму весовой функции внутри окна и оказывает незначительный эффект на итоговую ошибку.

2. Когда переменное окно выигрывает у фиксированного?

На однородных синтетических данных оба метода показывают сопоставимое качество. Однако переменное окно обладает теоретическим и практическим преимуществом в областях с неравномерной плотностью распределения объектов. Оно адаптивно сужается в плотных областях (что помогает сохранять высокую детализацию) и расширяется в разреженных.

3. При каком уровне зашумления данных LOWess начинает выигрывать у обычного сглаживания?

Обычное ядерное сглаживание линейно зависит от ответов и крайне чувствительно к любым аномалиям. LOWess начинает существенно выигрывать уже при 5–10% шума в данных. В нашем эксперименте 10% выбросов полностью исказили прогноз NW, тогда как LOWess за счёт итеративного обнуления весов аномалий успешно восстановил истинную зависимость.

8 Заключение

В ходе лабораторной работы были успешно реализованы и исследованы метрические методы регрессии. Мы убедились, что непараметрические подходы обладают высокой гибкостью и способны аппроксимировать сложные нелинейные зависимости без задания явного вида функции. Эксперименты показали, что ключевым фактором успеха является точная настройка ширины окна, а использование робастных схем, таких как LOWess, критически важно для работы с зашумлёнными данными. Применение методов на реальных датасетах наглядно продемонстрировало проблему проклятия размерности, подтвердив, что локальные методы лучше всего работают в пространствах малой размерности или требуют дополнительных этапов предобработки признаков.

Ссылки на ресурсы

- Репозиторий с кодом: github.com/Toxele/Functional-Analysis-Cases-5-6-7
- Использование ИИ-ассистента: chat.qwen.ai/s/a9391437-f773-48b6-8263-f058c297caf7