

ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ

Кейс 7: Аддитивная модель по мотивам теоремы Колмогорова

Выполнили:

Дубовик Никита Спартакович (Группа J3210)
Таряник Антон Александрович (Группа J3211)
Бессонов Александр Русланович (Группа J3213)

Содержание

1	Постановка задачи	2
2	Цели работы	3
3	Обоснование использования методов	3
4	Описание используемых датасетов	4
4.1	Синтетические данные	4
4.2	Diabetes	4
4.3	California Housing	4
5	Реализация алгоритмов	5
5.1	Аддитивная модель (AdditiveModel)	5
5.2	Полная нелинейная модель (FullNonLinearModel)	6
5.3	Используемые метрики качества	6
6	Экспериментальные результаты	7
6.1	Восстановление аддитивных компонент	7
6.2	Влияние числа базисных функций M	7
6.3	Сравнение типов базиса	8
6.4	Сравнение моделей на реальных датасетах	9
7	Выводы	10
8	Заключение	10
	Ссылки на ресурсы	11

1 Постановка задачи

Согласно теореме Колмогорова о представлении непрерывных функций, любая непрерывная функция многих переменных может быть представлена в виде суперпозиции непрерывных функций одного переменного и операции сложения. В упрощённой постановке задачи рассматривается аддитивная регрессионная модель:

$$f(x) = \beta_0 + \sum_{j=1}^p g_j(x_j),$$

где $x = (x_1, \dots, x_p) \in \mathbb{R}^p$ — вектор признаков, β_0 — свободный член, а $g_j(x_j)$ — одномерные функции компонент, каждая из которых зависит только от одного признака x_j .

Для аппроксимации функций g_j используется разложение по базису из M функций $\{\phi_m\}_{m=1}^M$:

$$g_j(x_j) = \sum_{m=1}^M \theta_{jm} \phi_m(x_j),$$

где θ_{jm} — подлежащие оцениванию параметры, а ϕ_m — базисные функции.

Подставляя разложение в общую модель, получаем линейную по параметрам модель:

$$f(x) = \beta_0 + \sum_{j=1}^p \sum_{m=1}^M \theta_{jm} \phi_m(x_j).$$

В матричной форме модель записывается как $y = Z\theta$, где Z — блочная матрица базисных функций размера $N \times (1 + p \cdot M)$, а θ — вектор всех параметров.

Параметры модели оцениваются методом наименьших квадратов (OLS) или Ridge-регрессией (L_2 -регуляризация):

$$\hat{\theta} = (Z^\top Z + \lambda I')^{-1} Z^\top y, \quad \text{где } \lambda \geq 0, \quad I'_{00} = 0.$$

Для обеспечения идентифицируемости модели компоненты $g_j(x_j)$ центрируются (имеют нулевое среднее), а средние значения переносятся в свободный член β_0 .

В работе рассматриваются два типа базисных функций:

- **Полиномиальный базис:** $\phi_m(x) = x^m$, $m = 1, \dots, M$;
- **Тригонометрический базис:** $\phi_{2k-1}(x) = \sin(2\pi kx)$, $\phi_{2k}(x) = \cos(2\pi kx)$, $k = 1, \dots, \lceil M/2 \rceil$.

Дополнительно для сравнения реализована полная нелинейная модель степени d , включающая всевозможные произведения признаков до степени d включительно (с попарными взаимодействиями), что соответствует общему полиному степени d от p переменных.

Также в работе генерируются неаддитивные синтетические данные вида $y = \sin(2\pi(x_1 + x_2)) + 0.5x_3 + \varepsilon$ для демонстрации случаев, когда аддитивная модель не способна точно восстановить истинную зависимость из-за наличия взаимодействий между признаками.

2 Цели работы

1. Реализовать с нуля аддитивную регрессионную модель с полиномиальным и тригонометрическим базисами, а также полную нелинейную модель для сравнения.
2. Исследовать способность модели восстанавливать истинные одномерные компоненты $g_j(x_j)$ на синтетических аддитивных данных.
3. Изучить влияние числа базисных функций M , типа базиса (полиномиальный vs тригонометрический) и параметра регуляризации λ на качество аппроксимации.
4. Провести сравнение трёх моделей (линейная, аддитивная, полная нелинейная) на реальных датасетах Diabetes и California Housing по метрикам MSE, RMSE и R^2 .
5. Сформулировать выводы о преимуществах и ограничениях аддитивных моделей, включая интерпретируемость, устойчивость к проклятию размерности и способность моделировать нелинейности.

3 Обоснование использования методов

Аддитивные модели выбраны в качестве объекта исследования по следующим причинам:

- **Интерпретируемость.** В отличие от «чёрных ящиков» (нейронные сети, градиентный бустинг), аддитивная модель позволяет визуализировать и анализировать вклад каждого признака в предсказание через компоненты $g_j(x_j)$. Это критически важно в задачах, где требуется объяснить принятое решение (медицина, финансы).
- **Борьба с проклятием размерности.** Полная нелинейная модель с взаимодействиями имеет число параметров, растущее экспоненциально с ростом p (например, для квадратичной модели $\sim p^2/2$). Аддитивная модель, напротив, имеет лишь $O(p \cdot M)$ параметров, что позволяет применять её при значительно большем числе признаков.
- **Гибкость.** Благодаря выбору базисных функций (полиномиальные, тригонометрические и др.) модель способна аппроксимировать широкий класс нелинейных зависимостей.
- **Теоретическое обоснование.** Теорема Колмогорова гарантирует, что любая непрерывная функция может быть представлена в виде суперпозиции функций одного переменного, что даёт математическую основу для аддитивного подхода.

Однако аддитивные модели имеют ограничение: они не способны улавливать взаимодействия между признаками, что может приводить к потере качества на данных, где такие взаимодействия существенны.

4 Описание используемых датасетов

В работе используются синтетические и реальные датасеты.

4.1 Синтетические данные

Для проверки способности аддитивной модели восстанавливать истинные одномерные компоненты сгенерирован аддитивный синтетический датасет. Признаки x_1, x_2, x_3 независимо сэмпляются из равномерного распределения на отрезке $[0, 1]$. Целевая переменная формируется по аддитивному закону:

$$y_{\text{add}} = \sin(2\pi x_1) + \frac{1}{2}(x_2 - 0.5)^2 + e^{-3x_3} + \varepsilon,$$

где $\varepsilon \sim \mathcal{N}(0, 0.1^2)$ — нормальный шум. Объём выборки $N = 300$.

Для демонстрации ограничений аддитивной модели генерируется неаддитивный датасет, в котором целевая переменная включает взаимодействие признаков:

$$y_{\text{nonadd}} = \sin(2\pi(x_1 + x_2)) + 0.5x_3 + \varepsilon,$$

где $x_j \sim U[0, 1]$ и $\varepsilon \sim \mathcal{N}(0, 0.1^2)$. Данные содержат $N = 300$ наблюдений.

4.2 Diabetes

Датасет `diabetes` из библиотеки `scikit-learn` содержит медицинские данные о прогрессировании диабета. Характеристики датасета: $N = 442$ наблюдения, $p = 10$ признаков (возраст, пол, индекс массы тела, артериальное давление и шесть показателей сыворотки крови). Целевая переменная — количественная мера прогрессирования заболевания через год после исходного обследования. Для использования в моделях признаки нормированы в интервал $[0, 1]$ методом минимаксного масштабирования, целевая переменная оставлена без изменений.

4.3 California Housing

Датасет `california_housing` из библиотеки `scikit-learn` содержит информацию о стоимости жилья в Калифорнии на основе данных переписи 1990 года. Характеристики датасета: $N = 20\,640$ наблюдений, $p = 8$ признаков (медианный доход, возраст дома, среднее число комнат, среднее число спален, население, домохозяйства, широта, долгота). Целевая переменная — медианная стоимость дома в сотнях тысяч долларов. Признаки нормированы в интервал $[0, 1]$ методом минимаксного масштабирования. Данные разделены на обучающую и тестовую выборки в соотношении 80%/20%.

5 Реализация алгоритмов

Все алгоритмы реализованы с нуля на языке Python без использования готовых реализаций регрессионных моделей из `scikit-learn` (библиотека используется только для загрузки датасетов и разделения выборки).

5.1 Аддитивная модель (AdditiveModel)

Аддитивная модель реализована классом `AdditiveModel`. Она принимает три параметра: число базисных функций M , тип базиса (`'poly'` или `'trig'`) и коэффициент регуляризации α (эквивалент λ в теоретическом описании).

Построение матрицы Z . Для каждого признака x_j строится матрица базисных функций $B_j = [\phi_1(x_j), \dots, \phi_M(x_j)]$ размера $N \times M$. Общая матрица Z имеет блочную структуру:

$$Z = [\mathbf{1} \quad B_1 \quad B_2 \quad \dots \quad B_p],$$

где $\mathbf{1}$ — столбец из единиц (для свободного члена β_0). Размер матрицы Z составляет $N \times (1 + p \cdot M)$. Вектор параметров модели:

$$\theta = [\beta_0 \quad \theta_{11} \quad \dots \quad \theta_{1M} \quad \theta_{21} \quad \dots \quad \theta_{pM}]^\top.$$

Оценивание параметров. Параметры находятся методом наименьших квадратов:

- При $\alpha = 0$ (OLS) используется псевдообратная матрица:

$$\hat{\theta} = (Z^\top Z)^+ Z^\top y;$$

- При $\alpha > 0$ (Ridge-регрессия):

$$\hat{\theta} = (Z^\top Z + \alpha I')^{-1} Z^\top y,$$

где I' — модифицированная единичная матрица, у которой элемент $I'_{00} = 0$, чтобы свободный член β_0 не подвергался регуляризации.

Центрирование компонент. Для обеспечения идентифицируемости модели после оценивания параметров компоненты $g_j(x_j)$ центрируются. Для каждого $j = 1, \dots, p$ вычисляется среднее значение компоненты на обучающей выборке:

$$\bar{g}_j = \frac{1}{N} \sum_{i=1}^N (B_j^{(i)} \theta^{(j)}),$$

где $B_j^{(i)}$ — i -я строка матрицы B_j , а $\theta^{(j)}$ — соответствующий подвектор параметров. Далее эти средние вычитаются из компонент и прибавляются к свободному члену:

$$\beta_0^{\text{new}} = \beta_0 + \sum_{j=1}^p \bar{g}_j.$$

Таким образом, центрированные компоненты $\hat{g}_j(x_j) = B_j \theta^{(j)} - \bar{g}_j$ имеют нулевое среднее, а β_0^{new} интерпретируется как общее среднее отклика.

Предсказание и интерпретация. Метод `predict` возвращает предсказание $Z\theta$, а метод `predict_components` возвращает свободный член β_0 и список центрированных компонент $\hat{g}_j$ для анализа вклада каждого признака.

5.2 Полная нелинейная модель (FullNonLinearModel)

Класс `FullNonLinearModel` реализует полную полиномиальную регрессию степени d с взаимодействиями признаков. Матрица Z строится путём перебора всех комбинаций с повторениями индексов признаков длины от 1 до d . Для каждой комбинации индексов $(i_1, \dots, i_k)$ формируется столбец как поэлементное произведение $x_{i_1} \odot \dots \odot x_{i_k}$.

Число параметров модели для p признаков и степени d составляет

$$\dim(\theta) = 1 + \binom{p+d}{d} - 1 = \binom{p+d}{d},$$

что при $d = 2$ даёт $1 + p + p(p+1)/2$ параметров. Параметры оцениваются тем же способом, что и в аддитивной модели (OLS или Ridge), с отсутствием штрафа на свободный член.

Для экспериментов используется степень $d = 2$, что обеспечивает учёт всех линейных членов, квадратичных членов и попарных взаимодействий признаков.

5.3 Используемые метрики качества

Качество моделей оценивается следующими метриками, реализованными в модуле `shared/metrics.py`:

1. Среднеквадратичная ошибка (MSE):

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2;$$

2. Корень из среднеквадратичной ошибки (RMSE):

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2};$$

3. Коэффициент детерминации (R^2):

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2},$$

где $\bar{y} = \frac{1}{N} \sum_{i=1}^N y_i$ — среднее значение целевой переменной.

Эти метрики позволяют оценить как абсолютную (MSE, RMSE), так и относительную (R^2) точность предсказаний.

6 Экспериментальные результаты

6.1 Восстановление аддитивных компонент

На рисунке 1 представлены результаты восстановления аддитивных компонент $g_j(x_j)$ на синтетических аддитивных данных. Аддитивная модель обучалась с полиномиальным базисом ($M = 5$, $\alpha = 0.01$). Для визуализации наблюдения отсортированы по каждому признаку.




Рис. 1: Сравнение восстановленных компонент $\hat{g}_j(x_j)$ с истинными функциями. Пунктирная линия — истинная центрированная компонента, сплошная — предсказанная моделью.

Из графиков видно, что модель с высокой точностью восстанавливает все три компонента: синусоидальную (x_1), параболическую (x_2) и экспоненциальную (x_3). Незначительные отклонения наблюдаются лишь в областях с высокой кривизной истинных функций, что связано с ограниченной гибкостью полиномиального базиса при $M = 5$.

6.2 Влияние числа базисных функций M

Для исследования влияния сложности модели на качество аппроксимации проведена серия экспериментов с варьированием числа базисных функций M от 1 до 11. На рисунке 2 показана зависимость RMSE на обучающей и тестовой выборках от M .




Рис. 2: Зависимость RMSE от числа базисных функций M на аддитивных синтетических данных.

При $M = 1$ модель соответствует линейной регрессии (полиномиальный базис первой степени) и имеет наибольшую ошибку как на обучении, так и на тесте — модель недообучена. При увеличении M до 3 ошибка резко снижается на обеих выборках. В диапазоне $M = 3 \dots 7$ достигается плато: RMSE стабилизируется на уровне около 0.1 на тесте. При дальнейшем увеличении M наблюдается слабый рост тестовой ошибки при продолжающемся снижении тренировочной — начинается переобучение. Оптимальным для данной задачи является значение $M = 5 \dots 7$.

6.3 Сравнение типов базиса

На рисунке 3 представлено сравнение полиномиального и тригонометрического базисов при различных значениях M . Для каждого M модель обучается с $\alpha = 0.01$ на аддитивных синтетических данных.




Рис. 3: Сравнение полиномиального и тригонометрического базисов по RMSE на тестовой выборке при различных M .

Оба базиса демонстрируют сопоставимую точность при достаточном числе функций ($M \geq 3$). Тригонометрический базис показывает несколько лучшие результаты при малых M , особенно для восстановления периодической компоненты $\sin(2\pi x_1)$, поскольку синусоидальные функции базиса естественным образом подходят для аппроксимации таких зависимостей. Полиномиальный базис более универсален и менее склонен к осцилляциям на границах области определения признаков.

6.4 Сравнение моделей на реальных датасетах

В таблицах 1 и 2 приведены результаты сравнения трёх моделей (линейной, аддитивной и полной нелинейной степени 2) на датасетах Diabetes и California Housing. Все модели обучены с Ridge-регуляризацией $\alpha = 0.1$, аддитивная модель использует полиномиальный базис с $M = 3$.

Таблица 1: Метрики моделей на датасете Diabetes (тестовая выборка)

Модель	Число параметров	MSE	RMSE	R^2
Линейная	11	2900.19	53.85	0.4526
Аддитивная ($M=3$)	31	2777.33	52.70	0.4758
Полная нелинейная ($\text{deg} = 2$)	66	2565.70	50.65	0.5157

Таблица 2: Метрики моделей на датасете California Housing (тестовая выборка)

Модель	Число параметров	MSE	RMSE	R^2
Линейная	9	0.5559	0.7456	0.5758
Аддитивная ($M=3$)	25	0.5139	0.7169	0.6079
Полная нелинейная ($\text{deg} = 2$)	45	0.5067	0.7118	0.6133

Результаты показывают устойчивую закономерность на обоих датасетах: линейная модель имеет наихудшие показатели по всем метрикам, полная нелинейная модель — наилучшие, а аддитивная модель занимает промежуточное положение. При этом аддитивная модель существенно превосходит линейную (на Diabetes улучшение R^2 с 0.453 до 0.476, на California Housing — с 0.576 до 0.608), что свидетельствует о наличии нелинейных зависимостей в данных. Дальнейшее улучшение при переходе к полной нелинейной модели (до $R^2 = 0.516$ на Diabetes и 0.613 на California Housing) указывает на присутствие межпризнаковых взаимодействий, которые аддитивная модель не способна учесть, однако прирост качества относительно невелик, что говорит о доминировании аддитивных эффектов в рассматриваемых данных.

Следует также отметить различие в числе параметров: аддитивная модель при $M = 3$ использует в 2.1–2.8 раза больше параметров, чем линейная, но в 1.8–2.1 раза меньше, чем полная нелинейная, что подтверждает её промежуточное положение по сложности.

7 Выводы

На основе проведённых экспериментов сформулированы следующие выводы:

1. **Аддитивная декомпозиция.** Модель успешно выделяет одномерные нелинейные компоненты $g_j(x_j)$ из данных. Визуальное сравнение с истинными функциями на синтетических данных подтвердило высокую точность восстановления, что делает модель ценным инструментом для интерпретации влияния отдельных признаков.
2. **Число базисных функций M .** При малых M модель недообучена. Оптимальное значение M лежит в диапазоне $3 \dots 7$ для типичных задач; дальнейшее увеличение слабо улучшает качество и может вести к переобучению. Подбор M следует осуществлять по валидационной выборке.
3. **Тип базиса.** Полиномиальный и тригонометрический базисы демонстрируют сопоставимую точность при достаточном M . Тригонометрический базис предпочтителен при ожидаемых периодических зависимостях и малых M . Полиномиальный базис более универсален и менее склонен к осцилляциям.
4. **Сравнение с альтернативами.** Аддитивная модель занимает промежуточное положение между линейной и полной нелинейной моделями как по качеству, так и по сложности. Она существенно превосходит линейную модель при наличии нелинейных зависимостей, уступая полной нелинейной лишь в задачах с сильными межпризнаковыми взаимодействиями.
5. **Интерпретируемость.** Возможность извлечения и визуализации компонент $g_j(x_j)$ выгодно отличает аддитивную модель от «чёрных ящиков». Это особенно ценно в прикладных областях (медицина, эконометрика), где важно не только предсказание, но и понимание природы зависимостей.
6. **Регуляризация.** Ridge-регуляризация (L_2) со свободным от штрафа свободным членом позволяет стабилизировать решение при избыточном M и мультиколлинеарности базисных функций.
7. **Ограничения.** Аддитивная модель принципиально не способна улавливать взаимодействия признаков (например, $x_1 \cdot x_2$), что подтверждается на неаддитивных синтетических данных. Для задач с сильными взаимодействиями следует использовать полную нелинейную модель или другие методы (градиентный бустинг, нейронные сети).

8 Заключение

В ходе работы была реализована и исследована аддитивная регрессионная модель, основанная на идеях теоремы Колмогорова. Показано, что модель сочетает в себе интерпретируемость линейных методов и способность моделировать нелинейные зависимости полных нелинейных моделей, занимая промежуточное положение по соотношению качество/сложность. Практические эксперименты на синтетических и реальных данных подтвердили эффективность аддитивного подхода в задачах без сильных межпризнаковых взаимодействий.

Ссылки на ресурсы

- Репозиторий с кодом: github.com/Toxele/Functional-Analysis-Cases-5-6-7
- Использование ИИ-ассистента: <https://opncl.ai/share/k7j6Xiec>