

Кейс 5: метрические методы классификации

Пусть дана обучающая выборка

$$X^\ell = \{(x_i, y_i)\}_{i=1}^\ell, \quad x_i \in \mathbb{R}^n, \quad y_i \in Y$$

Для измерения близости объектов используется взвешенная метрика Минковского

$$\rho(x, x_i) = \left(\sum_{j=1}^n w_j |x^j - x_i^j|^p \right)^{1/p}$$

где $w_j > 0$ – веса признаков, $p \geq 1$ – параметр метрики.

Пусть объекты обучающей выборки упорядочены по возрастанию расстояния до объекта x :

$$\rho(x, x_{(1)}) \leq \rho(x, x_{(2)}) \leq \dots \leq \rho(x, x_{(\ell)})$$

Рассматривается обобщённый метрический классификатор

$$a(x; X^\ell) = \arg \max_{y \in Y} \Gamma_y(x)$$

где

$$\Gamma_y(x) = \sum_{i=1}^{\ell} [y_{(i)} = y] w(i, x)$$

Требуется исследовать частные случаи данного правила:

- метод ближайшего соседа:

$$w(i, x) = [i \leq 1]$$

- метод k ближайших соседей:

$$w(i, x) = [i \leq k]$$

- метод k взвешенных ближайших соседей:

$$w(i, x) = [i \leq k] v_i$$

где v_i – убывающие веса соседей;

- метод окна Парзена фиксированной ширины:

$$a(x; X^\ell, h, K) = \arg \max_{y \in Y} \sum_{i=1}^{\ell} [y_i = y] K\left(\frac{\rho(x, x_i)}{h}\right)$$

- метод окна Парзена переменной ширины:

$$a(x; X^\ell, k, K) = \arg \max_{y \in Y} \sum_{i=1}^{\ell} [y_i = y] K\left(\frac{\rho(x, x_i)}{\rho(x, x_{(k+1)})}\right)$$

- профиль компактности

$$\Pi(m) = \frac{1}{L} \sum_{i=1}^L [y_i \neq y_i^{(m)}]$$

- качество метода 1NN по полному скользящему контролю;
- задачу отбора эталонов $\Omega \subseteq X^\ell$ для ускорения классификации без существенного ухудшения качества.

Задания для работы

1. Реализовать с нуля следующие алгоритмы:
 - 1NN
 - k NN
 - weighted- k NN
 - окно Парзена фиксированной ширины
 - окно Парзена переменной ширины
2. Подобрать параметры k , p , h и вид ядра K по критерию LOO.
3. Проверить влияние предварительного масштабирования признаков на качество классификации.
4. Для двумерного синтетического датасета построить карты классификации и границы решения для разных значений k и h .
5. Построить графики:
 - зависимость LOO-ошибки от k
 - зависимость LOO-ошибки от h
 - зависимость качества от параметра p в метрике Минковского
6. Исследовать, в каких задачах weighted- k NN устойчивее обычного k NN.
7. Реализовать вычисление профиля компактности $\Pi(m)$ и проверить, коррелирует ли он с качеством 1NN на выбранных датасетах.
8. Реализовать простой жадный алгоритм отбора эталонов:
 - последовательное удаление объектов
 - последовательное добавление объектов

Сравнить полный 1NN и 1NN по эталонам по качеству и времени предсказания.
9. Сформулировать не менее трёх выводов о том, как выбор метрики, ширины окна и числа соседей влияет на качество и устойчивость алгоритма.

Данные для работы

Для выполнения задания рекомендуется использовать не менее двух реальных датасетов (sklearn.datasets) и один синтетический.

- Iris – многоклассовая задача классификации
- Wine – многоклассовая задача с числовыми признаками
- Breast Cancer Wisconsin – бинарная классификация
- make_moons или make_classification – синтетические данные для визуализации границ решения